

Sistema Inteligente de Apoio ao Diagnóstico de Câncer de Mama

Projeto: FIAP – IADT Fase 1 – Tech Challenge B

Tema: Machine Learning aplicado ao apoio ao diagnóstico médico

Dataset: Breast Cancer Wisconsin Diagnostic Dataset

Problema: Classificação de tumores em benignos ou malignos

Autor: Wesley Adolpho de Lima Klein

Curso: IA para Devs - Pós Tech - 9IADT **Data:** 01/05/2026

1. Resumo Executivo

Este projeto apresenta a construção de uma solução inicial de Inteligência Artificial com foco em Machine Learning para apoiar a análise inicial de exames médicos. A proposta está alinhada ao desafio da FIAP, que solicita uma solução capaz de processar dados médicos e auxiliar equipes clínicas na triagem e no suporte à decisão.

A base escolhida foi o **Breast Cancer Wisconsin**, um dataset público utilizado para classificação de tumores de mama em duas classes: **benigno** e **maligno**. O objetivo principal foi construir, comparar e avaliar modelos de classificação capazes de identificar corretamente casos malignos, reduzindo principalmente o risco de **falsos negativos**.

No contexto médico, um falso negativo ocorre quando o modelo classifica um tumor maligno como benigno. Esse é o erro mais crítico do problema, pois pode atrasar a investigação médica e comprometer o tratamento do paciente. Por esse motivo, a métrica priorizada neste trabalho foi o **recall da classe maligna**.

Após a exploração dos dados, limpeza, pré-processamento, treinamento de modelos, validação cruzada e otimização com **GridSearchCV**, o melhor modelo identificado foi a **Regressão Logística otimizada**, que apresentou ótimo equilíbrio entre desempenho, interpretabilidade e sensibilidade para identificar tumores malignos.

2. Contextualização do Problema

Um hospital universitário deseja implementar uma solução inteligente de apoio ao diagnóstico médico. O objetivo não é substituir médicos, mas oferecer uma ferramenta de apoio que ajude na análise inicial de exames e dados clínicos.

Neste projeto, a abordagem foi baseada em dados estruturados. Cada registro da base representa características extraídas de exames de células da mama, e o modelo deve prever se o tumor é benigno ou maligno.

2.1 Tipo de problema

O problema é uma **classificação supervisionada binária**.

Isso significa que:

- O modelo recebe exemplos já classificados.
- Cada exemplo possui variáveis de entrada, chamadas de features.
- Cada exemplo possui uma resposta conhecida, chamada de variável alvo.
- O objetivo é aprender padrões nos dados para prever novos casos.

2.2 Classes do problema

Código	Classe	Significado
0	Benigno	Tumor não cancerígeno
1	Maligno	Tumor cancerígeno

A classe mais crítica é a classe **1**, pois representa os casos malignos.

3. Dataset Utilizado

O dataset utilizado foi o **Breast Cancer Wisconsin Diagnostic Dataset**, disponível publicamente no Kaggle.

A base contém medidas numéricas extraídas de imagens digitalizadas de punção aspirativa por agulha fina de massas mamárias. Essas medidas descrevem características das células analisadas, como raio, textura, perímetro, área, suavidade, compactação, concavidade, pontos côncavos, simetria e dimensão fractal.

3.1 Estrutura inicial da base

Na exploração inicial, a base possuía:


Item	Valor
Registros	569
Colunas iniciais	33
Variável alvo original	diagnosis
Coluna identificadora	id
Coluna vazia	Unnamed: 32

Coluna identificadora e vazia foram removidas

3.2 Distribuição das classes

Classe	Quantidade	Percentual aproximado
Benigno	357	62,7%
Maligno	212	37,3%

A base é considerada **moderadamente desbalanceada**, pois há mais casos benignos do que malignos. Isso exige cuidado na escolha das métricas, porque uma acurácia alta pode esconder problemas na identificação da classe minoritária.



4. Dicionário de Dados

As colunas originais foram traduzidas para português para facilitar a leitura e a apresentação do projeto.

4.1 Variável alvo

Coluna original	Coluna em português	Descrição
diagnosis	diagnostico	Resultado do diagnóstico: 0 para benigno e 1 para maligno

4.2 Variáveis principais: médias

As colunas com sufixo `_mean` representam o valor médio das características analisadas.

Coluna original	Coluna em português	Descrição
radius_mean	raio_media	Média das distâncias do centro até a borda da célula
texture_mean	textura_media	Variação média dos tons de cinza na imagem
perimeter_mean	perimetro_media	Perímetro médio das células analisadas
area_mean	area_media	Área média das células analisadas
smoothness_mean	suavidade_media	Variação local média no raio da célula
compactness_mean	compactacao_media	Medida média de compactação da célula

Coluna original	Coluna em português	Descrição
concavity_mean	concavidade_media	Grau médio de concavidade do contorno celular
concave_points_mean	pontos_concavos_media	Quantidade média de pontos côncavos no contorno
symmetry_mean	simetria_media	Simetria média da célula
fractal_dimension_mean	dimensao_fractal_media	Complexidade média do contorno celular

4.3 Variáveis de erro padrão

As colunas com sufixo `_se` representam o erro padrão das medições.

Coluna original	Coluna em português	Descrição
radius_se	raio_erro_padrao	Erro padrão do raio
texture_se	textura_erro_padrao	Erro padrão da textura
perimeter_se	perimetro_erro_padrao	Erro padrão do perímetro
area_se	area_erro_padrao	Erro padrão da área
smoothness_se	suavidade_erro_padrao	Erro padrão da suavidade
compactness_se	compactacao_erro_padrao	Erro padrão da compactação
concavity_se	concavidade_erro_padrao	Erro padrão da concavidade
concave_points_se	pontos_concavos_erro_padrao	Erro padrão dos pontos côncavos
symmetry_se	simetria_erro_padrao	Erro padrão da simetria
fractal_dimension_se	dimensao_fractal_erro_padrao	Erro padrão da dimensão fractal

4.4 Variáveis de pior caso

As colunas com sufixo `_worst` representam os maiores ou piores valores observados entre as medições. Elas são importantes porque podem destacar alterações mais intensas relacionadas a malignidade.

Coluna original	Coluna em português	Descrição
radius_worst	raio_pior	Pior valor observado para raio
texture_worst	textura_pior	Pior valor observado para textura
perimeter_worst	perimetro_pior	Pior valor observado para perímetro
area_worst	area_pior	Pior valor observado para área
smoothness_worst	suavidade_pior	Pior valor observado para suavidade
compactness_worst	compactacao_pior	Pior valor observado para compactação

Coluna original	Coluna em português	Descrição
<code>concavity_worst</code>	<code>concavidade_pior</code>	Pior valor observado para concavidade
<code>concave_points_worst</code>	<code>pontos_concavos_pior</code>	Pior valor observado para pontos côncavos
<code>symmetry_worst</code>	<code>simetria_pior</code>	Pior valor observado para simetria
<code>fractal_dimension_worst</code>	<code>dimensao_fractal_pior</code>	Pior valor observado para dimensão fractal

5. Análise Exploratória dos Dados

A análise exploratória teve como objetivo entender a estrutura da base, validar a qualidade dos dados e identificar possíveis relações entre as variáveis e o diagnóstico.

5.1 Verificação inicial

Foram realizadas as seguintes verificações:

- Quantidade de linhas e colunas.
- Tipos de dados.
- Valores ausentes.
- Colunas vazias.
- Duplicidade de identificadores.
- Distribuição da variável alvo.

5.2 Valores ausentes

A base não apresentou valores ausentes relevantes nas variáveis úteis. A única coluna completamente vazia foi `Unnamed: 32`, removida durante a limpeza.

5.3 Duplicidade de IDs

Foi verificado que não havia IDs duplicados. Isso indica que cada registro representa um caso distinto.

6. Limpeza dos Dados

A etapa de limpeza preparou a base para a modelagem.

6.1 Remoção de colunas desnecessárias

Foram removidas as colunas:

Coluna	Motivo da remoção
<code>id</code>	Identificador do registro, sem valor preditivo para o modelo
<code>Unnamed: 32</code>	Coluna vazia, sem informação útil

A coluna `id` é importante para controle da base, mas não deve ser usada no treinamento, pois não representa característica clínica do tumor.

6.2 Conversão da variável alvo

A coluna original **diagnosis** possuía valores categóricos:

Valor original	Conversão	Significado
B	0	Benigno
M	1	Maligno

Essa conversão foi necessária porque os algoritmos de Machine Learning trabalham melhor com dados numéricos. Além disso, definir maligno como **1** facilita a interpretação das métricas da classe positiva.

6.3 Tradução das colunas

As colunas foram traduzidas para português para facilitar a análise, documentação e apresentação do projeto.

6.4 Resultado da limpeza

Após a limpeza, a base ficou com:

Item	Valor
Registros	569
Variável alvo	diagnostico
Variáveis preditoras	30
Total de colunas	31


7. Análise de Correlação

A análise de correlação foi utilizada para identificar quais variáveis possuem maior associação com o diagnóstico maligno.

A correlação varia de -1 a 1:

Valor	Interpretação
Próximo de 1	Forte associação positiva
Próximo de 0	Baixa ou nenhuma associação linear
Próximo de -1	Forte associação negativa

Como a variável **diagnostico** foi codificada com **1 = maligno**, correlações positivas indicam variáveis que tendem a aumentar quando o tumor é maligno.



7.1 Variáveis mais correlacionadas com malignidade

Variável	Correlação com diagnostico	Interpretação
pontos_concavos_pior	0.793566	Forte associação com malignidade
perimetro_pior	0.782914	Tumores malignos tendem a apresentar maior perímetro
pontos_concavos_media	0.776614	Irregularidade média do contorno é relevante
raio_pior	0.776454	Tumores malignos tendem a apresentar maior raio
perimetro_media	0.742636	Perímetro médio se associa à classe maligna
area_pior	0.733825	Área elevada aparece fortemente associada à malignidade

Variável	Correlação com diagnostico	Interpretação
raio_media	0.730029	Raio médio maior tende a aparecer em tumores malignos
area_media	0.708984	Área média maior tende a indicar maior risco
concavidade_media	0.696360	Concavidade média é um indicador importante
concavidade_pior	0.659610	Concavidade no pior caso também é relevante

7.2 Interpretação clínica dos padrões

Os resultados mostram que variáveis relacionadas a **tamanho, área, perímetro, concavidade e pontos côncavos** possuem forte associação com a malignidade.

De forma simplificada, tumores malignos tendem a apresentar:

- Formato mais irregular.
- Maior área.
- Maior perímetro.
- Mais concavidades.
- Mais pontos côncavos.

Essa análise ajuda a justificar por que essas variáveis aparecem posteriormente como importantes nos modelos.

8. Preparação dos Dados para Modelagem

Após a limpeza e análise exploratória, os dados foram preparados para treinamento dos modelos.

8.1 Separação entre X e y

Foram separados:

Elemento	Descrição
X	Variáveis de entrada, ou seja, as características do tumor
y	Variável alvo, ou seja, o diagnóstico

A coluna **diagnostico** foi removida de X e armazenada em y.

Aqui vamos realizar a separação dos dados em partes de treino e teste.

```
# Separar os dados entre treino e teste.
# Aqui usamos 80% para treinar o modelo e 20% para avaliar
# seu desempenho em dados que ele ainda não viu.
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42
)

# Validar o tamanho dos conjuntos gerados após a separação.
# Esses valores ajudam a confirmar se a divisão treino/teste foi aplicada corretamente.
print("X_train:", X_train.shape)
print("X_test:", X_test.shape)
print("y_train:", y_train.shape)
print("y_test:", y_test.shape)
```

[2]

```
... X_train: (455, 30)
    X_test: (114, 30)
    y_train: (455,)
    y_test: (114,)
```

Python

8.2 Separação treino e teste

Foi utilizado `train_test_split` para separar a base em dados de treino e teste.

Conjunto	Percentual	Finalidade
Treino	80%	Usado para treinar o modelo
Teste	20%	Usado para avaliar o modelo em dados não vistos

O conjunto de teste simula novos casos que o modelo ainda não conhece.

8.3 Uso de `stratify=y`

Foi recomendado o uso de `stratify=y` para preservar a proporção entre benignos e malignos nos conjuntos de treino e teste.

Isso é importante porque a base possui leve desbalanceamento. Sem estratificação, o conjunto de teste poderia ficar com proporção diferente da base original, prejudicando a avaliação.

8.4 Padronização com `StandardScaler`

Foi utilizado `StandardScaler` para padronizar as variáveis numéricas.

A padronização transforma os dados para que fiquem com:

- Média próxima de 0.
- Desvio padrão próximo de 1.

Essa etapa é importante principalmente para modelos sensíveis à escala, como:

- Regressão Logística.

- KNN.

A Árvore de Decisão não depende tanto de padronização, mas manter um pipeline padronizado facilita a comparação entre modelos.

```

=== ANTES DA NORMALIZAÇÃO ===
Maior |média| antes: 876.9870329670329
Maior desvio populacional antes: 567.0486811155926
Maior desvio amostral antes: 567.672840557284

=== APÓS A NORMALIZAÇÃO ===
Maior |média| após normalização: 6.754060070686666e-16
Maior |desvio populacional - 1|: 2.220446049250313e-16
Maior |desvio amostral - 1|: 0.0011007157982689808

Primeiras colunas validadas:

```

	media_antes	desvio_pop_antes	desvio_amostral_antes	\
raio_media	14.117635	3.531928	3.535815	
textura_media	19.185033	4.261314	4.266005	
perimetro_media	91.882242	24.295284	24.322027	
area_media	654.377582	354.552925	354.943187	
suavidade_media	0.095744	0.013908	0.013923	



	media_apos	desvio_pop_apos	desvio_amostral_apos	
raio_media	-3.162306e-16	1.0	1.001101	
textura_media	-3.513673e-17	1.0	1.001101	
perimetro_media	-1.132183e-16	1.0	1.001101	
area_media	3.669836e-16	1.0	1.001101	
suavidade_media	-2.381489e-16	1.0	1.001101	

8.5 Observação sobre valores negativos após normalização


Após a padronização, é normal aparecerem valores negativos. Isso não significa que o dado está errado.

Um valor negativo indica apenas que aquela observação está abaixo da média daquela variável. Por exemplo:

- Valor padronizado positivo: acima da média.
- Valor padronizado negativo: abaixo da média.
- Valor próximo de zero: próximo da média.




A Arquitetura da Pipeline



9. Modelos Utilizados

Foram utilizados três modelos de classificação para comparação.



9.1 Regressão Logística

A Regressão Logística é um modelo linear usado para classificação. Apesar do nome conter “regressão”, ela é muito usada em problemas de classificação binária.


Ela estima a probabilidade de um caso pertencer à classe positiva. Neste projeto, a classe positiva é o tumor maligno.

Vantagens:

- Boa performance em bases tabulares.
- Fácil interpretação.
- Permite analisar coeficientes.
- Boa opção para contexto médico por ser mais explicável.

Resultado:

Acurácia: 0.9737				
	precision	recall	f1-score	support
0	0.97	0.99	0.98	71
1	0.98	0.95	0.96	43
accuracy			0.97	114
macro avg	0.97	0.97	0.97	114
weighted avg	0.97	0.97	0.97	114



9.2 Árvore de Decisão

A Árvore de Decisão cria regras de decisão baseadas nas variáveis do dataset.

Vantagens:


- Fácil visualização.
- Fácil explicação.
- Permite analisar importância das variáveis.

Limitações:


- Pode sofrer overfitting se a profundidade não for controlada.
- Pode ser menos estável que modelos lineares.

Resultado:

Acurácia (Árvore): 0.9474					
	precision	recall	f1-score	support	
0	0.96	0.96	0.96	71	
1	0.93	0.93	0.93	43	
accuracy			0.95	114	
macro avg	0.94	0.94	0.94	114	
weighted avg	0.95	0.95	0.95	114	



- Visualizar Árvore



9.3 KNN

O KNN classifica um novo caso com base nos exemplos mais próximos no conjunto de treino.

Vantagens:


- Simples de entender.
- Pode funcionar bem em bases pequenas.

Limitações:

- Sensível à escala dos dados.
- Pode perder desempenho com muitas variáveis.
- Menos interpretável que a Regressão Logística e a Árvore.


Resultado (5 vizinhos):

	precision	recall	f1-score	support
0	0.96	0.96	0.96	71
1	0.93	0.93	0.93	43
accuracy			0.95	114
macro avg	0.94	0.94	0.94	114
weighted avg	0.95	0.95	0.95	114



Resultado (9 vizinhos):

	precision	recall	f1-score	support
0	0.97	0.97	0.97	71
1	0.95	0.95	0.95	43
accuracy			0.96	114
macro avg	0.96	0.96	0.96	114
weighted avg	0.96	0.96	0.96	114



Para o KNN também testamos diferentes valores de k


K=3 → Acurácia: 0.9474 K=5 → Acurácia: 0.9474 K=7 → Acurácia: 0.9474 K=9 → Acurácia: 0.9649

10. Resultados Iniciais dos Modelos

A primeira comparação foi feita com os modelos base.

A Arena de Modelos: Primeira Triagem

	Modelo	Acurácia	Recall (Classe 1)
Vencedor Inicial	Regressão Logística	0.9736	0.9534
	Árvore de Decisão	0.9473	0.9302
	KNN (k=5)	0.9473	0.9302
	KNN (k=9)	0.9649	0.9534



A Regressão Logística assumiu a liderança com o melhor equilíbrio inicial, permitindo apenas 2 falsos negativos.

Modelo	Acurácia	Precisão Classe 1	Recall Classe 1	F1-score Classe 1
Regressão Logística	0.973684	0.976190	0.953488	0.964706
Árvore de Decisão	0.947368	0.930233	0.930233	0.930233
KNN k=5	0.947368	0.930233	0.930233	0.930233
KNN k=9	0.964912	0.953488	0.953488	0.953488

10.1 Interpretação dos resultados iniciais

A Regressão Logística teve o melhor desempenho inicial geral. Ela apresentou alta acurácia e bom recall para a classe maligna.

A Árvore de Decisão e o KNN com k=5 apresentaram desempenho semelhante, mas inferior ao da Regressão Logística.

O KNN com k=9 melhorou em relação ao KNN com k=5, alcançando recall semelhante ao da Regressão Logística inicial.

11. Matriz de Confusão

A matriz de confusão é uma das formas mais importantes de avaliar um modelo de classificação, pois mostra onde o modelo acertou e onde errou.

11.1 Conceitos

Termo	Significado no projeto
TN	Benigno previsto como benigno
TP	Maligno previsto como maligno
FP	Benigno previsto como maligno
FN	Maligno previsto como benigno

11.2 Matriz da Regressão Logística inicial

Situação	Quantidade	Interpretação
TN	70	Casos benignos corretamente classificados
FP	1	Caso benigno classificado como maligno
FN	2	Casos malignos classificados como benignos
TP	41	Casos malignos corretamente classificados

11.3 Matriz da Regressão Logística Otimizada

Nesta etapa, utilizamos o threshold de **0.45** como ponto de corte para a decisão da Regressão Logística Otimizada. Com esse ajuste, o modelo passou a ser mais sensível na identificação da classe maligna e reduziu os falsos negativos de **2 para 1**. Em outras palavras, deixou de não identificar dois tumores malignos e passou a deixar apenas um caso sem identificação no conjunto de teste.

O melhor ponto de corte observado foi **0.45**, pois a partir desse valor não houve melhora adicional na identificação dos casos malignos. Dessa forma, o único caso não identificado nesse cenário pode ser entendido como um caso residual dentro da amostra avaliada.


Threshold 0.50

- Acertou 70 benignos.
- Errou 1 benigno como maligno.
- Deixou passar 2 malignos como benignos.
- Acertou 41 malignos.

Threshold 0.45

- Acertou 70 benignos.
- Errou 1 benigno como maligno.
- Deixou passar apenas 1 maligno como benigno.
- Acertou 42 malignos.

	Threshold	Acurácia	Precisão Classe 1	Recall Classe 1	F1-score Classe 1	TN	FP	FN	TP
0	0.50	0.973684	0.976190	0.953488	0.964706	70	1	2	41
1	0.45	0.982456	0.976744	0.976744	0.976744	70	1	1	42
2	0.40	0.982456	0.976744	0.976744	0.976744	70	1	1	42
3	0.35	0.973684	0.954545	0.976744	0.965517	69	2	1	42
4	0.30	0.956140	0.913043	0.976744	0.943820	67	4	1	42
5	0.25	0.956140	0.913043	0.976744	0.943820	67	4	1	42



11.4 Análise dos falsos negativos

Com o ajuste do threshold para **0.45**, o modelo passou a deixar de identificar apenas **1 caso maligno**, em vez de 2. No contexto médico, essa melhora é relevante, pois reduz o risco de um tumor maligno passar despercebido na triagem inicial.

Mesmo com alta acurácia, a análise da matriz mostra que o projeto deve priorizar a redução dos falsos negativos, e o threshold **0.45** apresentou o melhor equilíbrio observado para esse objetivo.

12. Escolha da Métrica Principal

Em problemas médicos, nem todo erro tem o mesmo impacto.

12.1 Acurácia

A acurácia mede o percentual total de acertos.

Ela é útil, mas pode ser insuficiente em problemas médicos, especialmente quando há desbalanceamento entre as classes.

12.2 Precisão

A precisão responde à pergunta:

Dos casos que o modelo classificou como malignos, quantos realmente eram malignos?

Ela é importante para evitar alarmes falsos, mas não é a prioridade máxima neste projeto.

12.3 Recall

O recall responde à pergunta:

Dos casos que realmente eram malignos, quantos o modelo conseguiu identificar?

A fórmula é:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

No contexto deste projeto, o recall da classe maligna é a métrica mais importante, porque mede a capacidade do modelo de encontrar os tumores malignos.

12.4 Por que o recall é prioritário?

Porque o erro mais grave é o falso negativo.

Um falso negativo significa que:

- O tumor era maligno.
- O modelo classificou como benigno.
- O paciente poderia não ser encaminhado para investigação adicional.
- O diagnóstico e o tratamento poderiam ser atrasados.

Por isso, o modelo deve ser sensível aos casos malignos, mesmo que isso aumente um pouco o número de falsos positivos.

13. Validação Cruzada K-Fold

A validação cruzada foi utilizada para avaliar a robustez dos modelos.

13.1 O que é validação cruzada?

A validação cruzada divide os dados de treino em várias partes. O modelo é treinado e validado várias vezes, alternando qual parte será usada como validação.

Neste projeto, foi utilizado:

```
StratifiedKFold(n_splits=5)
```

Isso significa que o treino foi dividido em 5 partes, mantendo a proporção entre benignos e malignos em cada divisão.

13.2 Por que usar `StratifiedKFold`?

Como a base é moderadamente desbalanceada, é importante manter a proporção das classes em cada fold.

O **StratifiedKFold** evita que algum fold fique com muitos benignos ou poucos malignos, o que poderia gerar uma avaliação instável.


Resultado:

	Modelo	Acurácia Média	Precisão Média	Recall Médio	F1-score Médio
0	Regressão Logística	0.973669	0.986258	0.943632	0.963341
1	Árvore de Decisão	0.927993	0.929353	0.877852	0.899202
2	KNN	0.963096	0.975524	0.924585	0.948669

13.3 Evitando vazamento de dados

Na validação cruzada, a padronização precisa ser feita dentro de cada fold. Para isso, foi utilizado um pipeline com:

1. **StandardScaler**
2. Modelo



Essa estratégia evita **data leakage**, ou seja, evita que informações dos dados de validação sejam usadas durante o treinamento.

13.4 Resultados da validação cruzada

Modelo	Acurácia média	Precisão média	Recall médio	F1 médio
Regressão Logística	0.973669	0.986258	0.943632	0.963341
Árvore de Decisão	0.927993	0.929353	0.877852	0.899202
KNN	0.963096	0.975524	0.924585	0.948669

13.5 Interpretação

A Regressão Logística manteve o melhor equilíbrio geral na validação cruzada. Ela apresentou alta acurácia média e o melhor recall médio entre os modelos base.

Isso indica que o bom desempenho observado no teste não foi apenas sorte de uma divisão específica dos dados.

14. Otimização com GridSearchCV

Após avaliar os modelos base, foi aplicado **GridSearchCV** para buscar melhores hiperparâmetros.

14.1 O que é GridSearchCV?


O **GridSearchCV** testa várias combinações de hiperparâmetros e avalia qual combinação produz melhor resultado com validação cruzada.

Neste projeto, o objetivo do **GridSearchCV** foi maximizar o **recall da classe maligna**.

Por isso, foi usado:

```
scoring='recall'
```

Isso faz com que o processo de busca escolha os modelos que melhor identificam os casos malignos.



14.2 Melhores parâmetros encontrados

Modelo	Melhores parâmetros	Melhor recall médio na validação
Regressão Logística	<code>C=10, solver='liblinear'</code>	0.958467
KNN	<code>metric='manhattan', n_neighbors=3, weights='uniform'</code>	0.929234
Árvore de Decisão	<code>criterion='entropy', max_depth=2, min_samples_leaf=1, min_samples_split=2</code>	0.947059


14.3 Interpretação da melhoria

A melhoria do `GridSearchCV` ocorreu porque os modelos deixaram de usar parâmetros genéricos e passaram a usar combinações ajustadas para o objetivo do projeto.

No caso da Regressão Logística, a configuração `C=10` e `solver='liblinear'` aumentou a sensibilidade do modelo aos casos malignos. O resultado foi a redução de falsos negativos no conjunto de teste.

15. Resultados dos Modelos Otimizados

Modelo	Acurácia	Precisão Classe 1	Recall Classe 1	F1-score Classe 1
Regressão Logística Otimizada	0.973684	0.954545	0.976744	0.965517
KNN Otimizado	0.964912	0.953488	0.953488	0.953488
Árvore Otimizada	0.912281	0.836735	0.953488	0.891304



15.1 Análise da tabela final

A Regressão Logística Otimizada foi o melhor modelo final, pois apresentou:

- Maior recall da classe maligna.
- Melhor F1-score da classe maligna.
- Alta acurácia.
- Boa precisão.
- Boa interpretabilidade.


O KNN Otimizado apresentou bom resultado, mas recall menor que a Regressão Logística Otimizada.

A Árvore Otimizada conseguiu recall bom, mas teve queda significativa de precisão e acurácia. Isso indica que ela passou a classificar mais casos como malignos, aumentando falsos positivos.

16. Matriz de Confusão do Modelo Final

A matriz de confusão da Regressão Logística Otimizada foi:

Situação	Quantidade	Interpretação
TN	69	Benignos corretamente classificados
FP	2	Benignos classificados como malignos
FN	1	Maligno classificado como benigno
TP	42	Malignos corretamente classificados



16.1 Análise final da matriz

O modelo final identificou corretamente **42 dos 43 casos malignos** do conjunto de teste. Apenas **1 caso maligno** foi classificado como benigno.

Essa redução é importante porque diminui o risco de um caso grave passar despercebido na triagem inicial.

Por outro lado, o modelo classificou **2 casos benignos como malignos**. Embora isso possa gerar investigação adicional desnecessária, esse erro é menos grave do que deixar passar um caso maligno.

17. Ajuste de Threshold

17.1 O que é threshold?

Modelos como a Regressão Logística retornam uma probabilidade. Por padrão, o limite de decisão geralmente é 0.50.

Isso significa:

- Probabilidade menor que 0.50: classifica como benigno.
- Probabilidade maior ou igual a 0.50: classifica como maligno.


Esse limite é chamado de **threshold**.

17.2 Por que ajustar o threshold?

No contexto médico, pode ser interessante reduzir o threshold para tornar o modelo mais sensível aos casos malignos.

Ao reduzir o threshold, o modelo passa a sinalizar como malignos alguns casos que antes ficariam como benignos.

O Toque Clínico: Calibrar a Sensibilidade



Um algoritmo devolve probabilidades, não certezas assépticas. Por omissão, assume um corte aos 50%. Mas na medicina, o limite é maleável. Ao reduzir o **Threshold** de decisão para **0.45**, tornamos o modelo intencionalmente mais reativo aos tumores malignos, forçando-o a captar casos de fronteira.

17.3 Comparação entre thresholds

Threshold	Falsos Negativos	Casos malignos detectados	Acurácia global
0.50	2	41	0.973
0.45	1	42	0.982

O Impacto Tangível do Novo Limiar

Limiar Padrão (0.50)

- 2 Falsos Negativos
- 41 Casos Malignos Detetados
- Acurácia Global: 0.973

Limiar Clínico (0.45)

- **1 Falso Negativo**
- 42 Casos Malignos Detetados
- Acurácia Global: 0.982

O ajuste salvou um caso clínico. Um caso maligno que passaria despercebido foi corretamente sinalizado para biópsia, reduzindo o erro para uma única exceção.


17.4 Interpretação

Ao reduzir o threshold de 0.50 para 0.45, o modelo ficou mais sensível e conseguiu identificar um caso maligno adicional.

Na prática, isso significa que um tumor maligno que poderia passar despercebido passou a ser sinalizado para investigação.

17.5 Ponto de equilíbrio clínico

A análise mostrou que 0.45 foi um bom ponto de equilíbrio, pois melhorou a detecção de malignos sem gerar aumento desnecessário de falsos positivos.



Reduzir demais o threshold poderia gerar muitos alarmes falsos. Por isso, o threshold não deve ser escolhido apenas por desempenho matemático, mas considerando o impacto clínico.


18. Interpretabilidade do Modelo

A interpretabilidade é essencial em aplicações médicas. Um modelo não deve apenas prever, mas também permitir uma explicação sobre quais variáveis influenciaram a decisão.

18.1 Coeficientes da Regressão Logística

Na Regressão Logística, os coeficientes indicam a influência das variáveis na classificação.

- Coeficientes positivos aumentam a probabilidade de classificação como maligno.
- Coeficientes negativos reduzem a probabilidade de classificação como maligno.



18.2 Variáveis com maior impacto no modelo

Entre as variáveis destacadas, apareceram:

Variável	Interpretação
raio_erro_padrao	Variações maiores no raio podem indicar irregularidade
pontos_concavos_media	Pontos côncavos estão fortemente associados à malignidade
compactacao_media	Mede o grau de compactação celular
simetria_pior	Alterações na simetria podem indicar irregularidade
concavidade_pior	Concavidade elevada sugere contornos mais irregulares
textura_pior	Textura alterada pode contribuir para a classificação
area_erro_padrao	Variações na área ajudam a diferenciar padrões
area_pior	Área elevada aparece associada a malignidade
raio_pior	Raio elevado no pior caso é relevante
concavidade_erro_padrao	Variação da concavidade ajuda na separação das classes


18.3 Feature importance da Árvore

A Árvore Otimizada destacou principalmente:

Variável	Importância
pontos_concavos_media	0.761452

Variável	Importância
perimetro_pior	0.136251
raio_pior	0.102297

Isso reforça a análise de correlação: variáveis relacionadas à irregularidade e tamanho do tumor possuem forte relação com malignidade.



18.4 SHAP

SHAP (*Shapley Additive exPlanations*) foi utilizado neste projeto como uma técnica complementar de interpretabilidade local, com o objetivo de explicar por que o modelo classificou um caso específico como benigno ou maligno.

Enquanto os coeficientes da Regressão Logística oferecem uma visão global do comportamento do modelo, o SHAP foi usado para detalhar a contribuição de cada variável em previsões individuais. Assim, foi possível identificar quais características empurraram a decisão para a classe maligna e quais atuaram no sentido contrário.

Na prática, essa abordagem permitiu analisar casos específicos e mostrar, de forma visual e interpretável, o impacto de variáveis como raio, área, concavidade e pontos côncavos na predição final. Isso torna a decisão do modelo mais transparente e facilita a comunicação dos resultados em um contexto médico.

Dessa forma, no presente trabalho, o SHAP não substituiu a análise dos coeficientes nem a avaliação das métricas do modelo. Ele foi utilizado como complemento para reforçar a explicabilidade do sistema e oferecer uma justificativa mais clara para decisões individuais geradas pelo modelo final.

19. Resposta Clínica Interpretável

Uma forma simples de explicar uma predição seria:

O modelo classificou este tumor como maligno porque algumas características apresentaram valores associados a maior risco, principalmente raio elevado, área elevada, concavidade alta e presença de pontos côncavos. Essas variáveis indicam maior irregularidade e tamanho do tumor, padrões que, na base analisada, aparecem com maior frequência em casos malignos.

Essa explicação não deve ser interpretada como diagnóstico final. Ela apenas mostra os motivos estatísticos que influenciaram a decisão do modelo.

A decisão final sempre deve ser feita por um profissional de saúde.

20. Discussão Crítica

20.1 O modelo pode ser usado na prática?

O modelo pode ser usado como uma ferramenta de apoio à triagem, mas não como substituto do diagnóstico médico.

Ele poderia auxiliar em situações como:

- Priorização de casos suspeitos.
- Apoio à análise inicial.
- Segunda opinião automatizada.
- Identificação de casos que merecem investigação adicional.

20.2 Limitações

Apesar dos bons resultados, existem limitações:

- A base é relativamente pequena.
- O dataset é público e controlado, diferente de um ambiente hospitalar real.
- O modelo não considera histórico clínico completo do paciente.
- O modelo não substitui exames complementares.
- A validação externa em outros datasets seria necessária.

20.3 Risco de falso positivo

Ao priorizar recall, o modelo pode aumentar falsos positivos. Isso significa que alguns tumores benignos podem ser sinalizados como malignos.

Esse erro pode gerar ansiedade e exames adicionais, mas é geralmente menos grave do que um falso negativo em triagem oncológica.

20.4 Papel do médico

A IA deve apoiar a decisão, mas o médico deve ter a palavra final.

O modelo deve ser visto como ferramenta auxiliar para aumentar eficiência, reduzir erros e apoiar decisões clínicas, nunca como autoridade diagnóstica isolada.

20.5 Conclusão



21. Organização do Projeto

A estrutura sugerida do projeto é:

```
IADT-Fase1-Tech-challengeB/
├── data/
│   ├── breast-cancer-wisconsin-data.csv
│   └── breast-cancer-wisconsin-data-clean.csv
├── notebooks/
│   ├── 01_exploracao_dados.ipynb
│   ├── 02_clean.ipynb
│   ├── 03_clean_column.ipynb
│   ├── 04_correlation.ipynb
│   ├── 05_graphics.ipynb
│   ├── 06_data_division.ipynb
│   └── 07_model_comparison_and_tuning.ipynb
├── reports/
│   ├── figures/
│   ├── tables/
│   └── relatorio_final.pdf
├── requirements.txt
├── Dockerfile
└── README.md
```

25. Conclusão Final

O projeto demonstrou que é possível construir uma solução inicial de Machine Learning para apoio ao diagnóstico de câncer de mama utilizando dados estruturados.

A Regressão Logística Otimizada foi escolhida como melhor modelo final por apresentar o melhor equilíbrio entre desempenho, recall da classe maligna e interpretabilidade.

O principal objetivo do projeto foi reduzir falsos negativos, pois, em um contexto médico, deixar de identificar um tumor maligno é o erro mais grave.

O modelo final conseguiu identificar **42 dos 43 casos malignos** no conjunto de teste, mantendo alta acurácia e boa precisão.

Além disso, o ajuste do threshold para 0.45 mostrou que a sensibilidade do modelo pode ser calibrada de acordo com o contexto clínico, aumentando a capacidade de identificar casos malignos.

Mesmo com resultados promissores, o modelo deve ser utilizado apenas como ferramenta de apoio. A decisão final deve continuar sob responsabilidade médica.
